


PA AI Platform

Gestione Intelligente delle Richieste dei Cittadini

Una soluzione AI enterprise-ready per automatizzare il ciclo di vita delle richieste citizen-facing nella Pubblica Amministrazione italiana — con piena conformità GDPR e controllo umano garantito.



Il Problema: Richieste in Crescita, Risorse Limitate

Volume Elevato

Migliaia di richieste via PEC, email e ticket gestite interamente in modo manuale, con tempi di risposta variabili e risk di backlog.

Disomogeneità Operativa

Smistamento non standardizzato tra uffici, risposte incoerenti e difficoltà di tracciare l'iter delle pratiche nel tempo.

Governance e Compliance

Necessità crescente di tracciabilità, conformità GDPR e governance AI conforme alle direttive europee per il settore pubblico.



Obiettivo Progettuale

Automatizzare l'intero ciclo di presa in carico delle richieste, riducendo il carico operativo e aumentando la qualità del servizio — senza mai eliminare il presidio umano.

1

Classificazione

Categoria, priorità e ufficio competente assegnati automaticamente

2

Instradamento

Routing intelligente verso il team corretto in tempo reale

3

Bozza Risposta

Draft generato con tono PA formale, pronto per validazione operatore



Valore per la Pubblica Amministrazione

Efficienza Operativa

Ottimizzazione dei tempi di lavorazione e migliore allocazione delle risorse umane verso attività ad alto valore aggiunto.

Qualità del Servizio

Riduzione degli errori di smistamento tra uffici e risposte più coerenti e tempestive per il cittadino.

Trasparenza e Audit

Log completo di ogni evento AI, con supporto decisionale spiegabile e piena conformità ai requisiti di accountability pubblica.

Dati Utilizzati: Fonti e Caratteristiche

Dataset di Riferimento

Dataset sintetico realistico in lingua italiana, costruito su richieste PA multi-categoria con distribuzione rappresentativa degli scenari operativi reali.

Campi Chiave


- Testo richiesta, categoria, ufficio competente
- Priorità, stato, risposta operatore, timestamp



Limiti Noti

- Dati sintetici, non ancora reali
- Rumore intenzionale e class imbalance
- Duplicati e richieste ambigue inclusi

Approccio Metodologico End-to-End



La pipeline combina classificazione ML supervisionata, recupero semantico dei precedenti e generazione controllata via LLM locale — garantendo risultati coerenti e auditabili in ogni fase del processo.

Architettura della Soluzione



Backend FastAPI

API REST modulari per classificazione, retrieval, generazione bozza e spiegabilità dei risultati



Dashboard Streamlit

Interfaccia operativa per revisione, validazione e gestione delle richieste da parte degli operatori



SQLite Audit & Metadata

Persistenza locale di metadati, log eventi AI e tracciamento dei modelli utilizzati in ogni generazione



Deploy Locale

Esecuzione on-premise enterprise-ready, adatta a demo consulting e adozione progressiva multi-ente



Metriche di Valutazione e Risultati Attesi

Metriche del Modello

- **Classificazione:** Accuracy, Precision, Recall, F1-score, Confusion Matrix
- **Retrieval:** Pertinenza top-k dei casi storici recuperati
- **Operativo:** Tempo medio di gestione, tasso escalation, qualità bozze

↓ Lavoro Manuale

Riduzione attesa su triage e prima risposta

↑ Velocità Routing

Instradamento più rapido verso l'ufficio corretto

✓ Consistenza

Comunicazioni uniformi con controllo umano finale

Privacy, Etica e Governance AI



Un Approccio Responsabile

La piattaforma è progettata con GDPR-by-design: ogni dato è minimizzato, ogni azione AI è tracciata e ogni output è soggetto a revisione umana obbligatoria prima della

- ❗ L'AI non decide mai in autonomia: la validazione dell'operatore è un requisito architetturale, non una funzione opzionale.

Diamo uno sguardo alla [demo](#)



Roadmap Evolutiva e Prossimi Passi

1

Fase 1 – Pilot

Workshop con stakeholder, definizione KPI e avvio pilot su un dipartimento selezionato con misurazione baseline

2

Fase 2 – Integrazione

Connessione con canali PEC/protocollo reali, sistemi documentali interni e fine-tuning su dati anonimizzati

3

Fase 3 – Scale-Up

Policy engine, MLOps monitoring, controlli qualità avanzati e scaling verso architettura multi-ente

Approfondimento su Dataset Sintetico e Training

Un corpus realistico in italiano progettato per addestrare e valutare modelli di classificazione e generazione automatica su richieste dei cittadini.

5.250 record totali

Dataset sintetico ad alta fedeltà, costruito per simulare flussi reali di ticketing PA

Variabili chiave


request_id, category, office, priority, status, operator_response, created_at, resolved_at

Qualità controllata

Class imbalance controllata, richieste rumorose/ambigue, duplicati e casi spam inclusi



Distribuzione delle Categorie nel Dataset




Lettura operativa

Le categorie Tributi e Anagrafe dominano il volume, rispecchiando i flussi reali degli sportelli digitali PA. La classe Non Pertinente (258 record) garantisce al modello la capacità di rigettare richieste fuori perimetro — una feature critica per la qualità del servizio.



Il bilanciamento controllato tra classi consente un addestramento robusto.

Distribuzione delle Priorità nel Dataset




Coerenza con i sistemi reali di ticketing

La prevalenza di ticket Medium e Low riflette fedelmente la distribuzione tipica degli sportelli PA. La coda Urgent — pur ridotta — è rappresentata in misura sufficiente per addestrare il modello a riconoscere segnali critici senza sovra-generalizzare.



Il forte sbilanciamento verso le priorità basse rende il task di classificazione della priorità significativamente più complesso rispetto alla categorizzazione.



Architettura dei Modelli di Classificazione

Pipeline Principale

Embedding:

intfloat/multilingual-e5-small

Classificatore: LightGBM —

selezionato come best model sia per categoria che per priorità

Approccio efficiente, interpretabile e scalabile per ambienti PA con vincoli di risorse computazionali.

Pipeline Avanzata Alternativa

Modello: DistilBERT multilingual con fine-tuning supervisionato

Scope: classificazione sia di categoria che di priorità

Utilizzata come benchmark di qualità per valutare il delta prestazionale rispetto alla pipeline principale.

Metriche LightGBM – Classificazione Categoria

92,3%

Accuracy

Quota di predizioni corrette sul totale dei record di test

94,9%

Precision macro

Capacità di non generare falsi positivi tra le categorie

91,3%

Recall macro

Copertura effettiva delle richieste per ciascuna categoria


92,8%

F1 macro

Bilanciamento tra precision e recall su tutte le classi

- ✔ Performance solida su tutte le classi principali, con buona gestione della classe **Non Pertinente**. Il modello è pronto per validazione su dati reali anonimizzati.

Metriche LightGBM – Classificazione Priorità



Task complesso per natura

La classificazione della priorità è intrinsecamente più difficile: la distinzione tra Low, Medium, High e Urgent richiede segnali contestuali che il solo testo della richiesta non sempre fornisce.

⚠ Per migliorare il modello è necessario integrare **feature di business** (es. storico cittadino, tipo di servizio, SLA di ufficio) e **regole operative esplicite** definite dai responsabili di processo.

Metriche DistilBERT Fine-Tuning – Confronto

Classificazione Categoria

Accuracy: 92,1%

In linea con LightGBM

Precision: 96,1%

Superiore alla pipeline base

F1 macro: 93,0%

Migliore equilibrio complessivo

Classificazione Priorità

Accuracy: 40,4%

Non superiore a LightGBM


Precision: 10,1%

Significativamente degradata

F1 macro: 14,4%

Insufficiente per produzione

 DistilBERT è competitivo sulla categoria ma non risolve il problema della priorità. La raccomandazione è un approccio ibrido AI + regole operative con feature engineering dedicato.



Architettura RAG + LLM per la Generazione delle Risposte



Retrieval Semantico

Ricerca su indice FAISS alimentato da casi storici risolti e risposte degli operatori, per ancorare ogni bozza a precedenti verificati.



Modelli LLM Selezionabili

Tre opzioni disponibili: llama3, qwen3.5:4b, gemma3n:e2b — scelti per efficienza e qualità su testo italiano istituzionale.



Governance e Audit Trail

Ogni generazione registra il modello utilizzato, i documenti recuperati e la versione del prompt — piena tracciabilità per compliance e accountability.

Design del Prompt di Generazione

Ruolo e Vincoli Operativi

Il prompt definisce un assistente per operatori PA con tono formale istituzionale. I vincoli principali:

- Usare solo il contesto recuperato dal retrieval — nessuna invenzione di norme o procedure
- Non indicare tempi di attesa numerici: usare il placeholder [TEMPO_STIMATO]

Guardrail by Design

Il prompt incorpora guardrail specifici per evitare che il modello generi contenuti che potrebbero creare aspettative errate nel cittadino o esporre l'amministrazione a rischi legali.

Il placeholder [TEMPO_STIMATO] forza l'operatore a inserire un dato verificato prima dell'invio, mantenendo il controllo umano sul dato sensibile.

- Indicare sempre che l'output è una bozza da validare dall'operatore umano
- Output in italiano, chiaro e conciso, massimo 220 parole

Grazie per la vostra attenzione!

Siamo a vostra disposizione per qualsiasi domanda e per esplorare come queste soluzioni possono trasformare la vostra Pubblica Amministrazione.

Prossimi passi

Contattateci per approfondire i casi d'uso, definire le priorità o pianificare una demo personalizzata.

Contatti

Marco Grazioso

Email: mar.grazioso@gmail.com